

Aspectos léxicos, sintácticos y semánticos para DECAF

El proyecto para el curso de Construcción de Compiladores, consiste en la implementación de las fases de compilación para el lenguaje DECAF.

Consideraciones Léxicas

- Todas las palabras claves (if, while, etc.) son en minúsculas.
- El lenguaje es case-sensitive (ej: foo y Foo, son dos variables distintas)
- Los comentarios comienzan por // y terminan en el fin de línea
- El espacio en blanco se define como uno o más espacios, tabuladores, saltos de línea y comentarios.
- Las palabras claves e identificadores se encuentran separados por espacios en blanco.
- Los números, son valores decimales que van desde -2147483648 y 2147483647.
- Un char es cualquier caracter ASCII imprimible (32 al 126), además de contener las siguientes secuencias de escape: \\\, \', \", \t, \n.
- Las palabras reservadas son: **class, struct, true, false, void, if, else, while, return, int, char, boolean.**
- **Program**, no es una palabra reservada, simplemente es el nombre de la clase o programa que se está analizando.

Consideraciones Sintácticas

- Ver la definición de la gramática DECAF.

Consideraciones Semánticas.

- Un programa en DECAF, consiste en una declaración de una clase llamada **Program**. La clase consiste en declaraciones de métodos (procedimientos) y atributos (variables, estructuras). La declaración de atributos dentro de la clase, los marca como atributos globales, es decir que pueden ser utilizados en todos los métodos de la clase.
- El programa debe de tener una declaración de un método llamado **main**, el cual será el punto de partida en la ejecución del programa.
- Tipos
 - Los tipos básicos del lenguaje son **int, char y boolean**. Estos tipos básicos (y otros tipos derivados) se pueden utilizar como base para derivar nuevos tipos con la palabra reservada **struct**.
 - De todos los tipos del lenguaje (básicos y derivados) se pueden declarar arreglos de una dimensión (int[N], char[N], boolean[N]), cuyo tamaño es definido en tiempo de compilación. Debido a esto, no se puede declarar arreglos como parámetros.
- Ámbito
 - Una variable debe de ser declarada antes de su uso.
 - Un método puede ser llamado solamente luego de ser declarado (métodos recursivos son permitidos)
 - Existen dos ámbitos principales en el programa, el ámbito Global y el ámbito Local. El ámbito global es el que se introduce en la definición de la clase **Program**. El ámbito local es el que se introduce dentro de la definición de un método (variables locales y parámetros formales). Además dentro de las estructuras de control, pueden definirse nuevos ámbitos (es decir, cada <block> es un nuevo ámbito dentro de la ejecución del programa).
 - Los identificadores en un ámbito local, pueden ocultar identificadores y métodos del ámbito global.

- Identificadores en un ámbito local, pueden ocultar identificadores en ámbitos anteriores e identificadores y métodos en el ámbito global.
- Ningún identificador (y método en el caso de ámbito global) puede ser definido más de una vez en un mismo ámbito.
- Valores iniciales
 - Una variable tipo **int** tendrá un valor inicial de 0.
 - Una variable tipo **boolean** tendrá un valor inicial de **false**.
 - Las variables son inicializadas al momento de entrar en su ámbito.
- Asignación
 - `<location> = <expr>` copia el valor resultante de evaluar `<expr>` en `<location>`
 - En `<location> = <expr>`, `<location>` y `<expr>` deben de tener el mismo tipo. Si `<location>` se refiere a un arreglo, la posición debe de estar definida. Si `<location>` se refiere a una estructura, el miembro debe de estar definido.
- Invocación de métodos y valor devuelto
 - Los argumentos en el momento de invocar a un método se pasan por valor.
 - Los argumentos formales de un método son considerados variables locales del método y son inicializados por asignándole el valor que resulta de las expresiones de los argumentos. Los argumentos son evaluados de izquierda a derecha.
 - Un método que devuelva **void** solamente puede ser utilizado como `<statement>`, es decir que no puede ser utilizado en ninguna expresión. El método devuelve el control al método que lo llamo por medio de la palabra reservada **return** ó cuando se termina el texto del método.
 - Un método que devuelve un valor puede ser utilizado dentro de una `<expression>` y como `<statement>`. El resultado de la llamada es el resultado que se obtiene al evaluar `<expression>` en la instrucción **return <expression>**. El tipo de este resultado debe de ser el mismo que el tipo que devuelve el método.
- Sentencias de control
 - **if**
 - Primero se evalúa `<expr>`, si `<expr>` es del tipo **boolean** y tiene valor **true**, entonces se ejecuta el bloque correspondiente a **true**, de lo contrario si existe un **else**, se ejecuta su bloque correspondiente.
 - **while**
 - El bloque correspondiente, se ejecuta mientras que el tipo de `<expr>` sea **boolean** y tenga valor **true**.
- Expresiones
 - Las expresiones siguen las reglas normales de evaluación. Los paréntesis sirven para agrupar y modificar la precedencia de operadores.
 - La expresión `<location>` se evalúa al valor que contiene dicho `<location>`
 - Los operadores aritméticos `<arith_op>` y el `-` unario, poseen la precedencia y significado normalmente aceptada. Estos operadores son utilizados en variables del tipo **int**.
 - Los operadores relacionales `<rel_op>` se utilizan para comparar tipos expresiones del tipo **int**. La comparación devuelve un tipo **boolean**.
 - Los operadores de comparación `<eq_op>` se utilizan para comparar expresiones del tipo **int**, **char** y **boolean**. Las expresiones a comparar deben de tener el mismo tipo. Esta comparación devuelve un tipo **boolean**.
 - Los operadores booleanos `<cond_op>` se utilizan en expresiones con operandos tipo **boolean**. Dicha expresión se evaluará utilizando una evaluación en corto circuito, es decir la expresión del segundo operando no es evaluada o ejecutada si el resultado del primer operando determina el valor de toda la expresión.
- Funciones de Entrada/Salida
 - Se definirán firmas para métodos para entrada y salida de datos. Estas firmas generarán código ensamblador que implementen la lectura del teclado y

la impresión en pantalla específicamente. Los tipos de dato que se leerán del teclado e imprimirán en pantalla son **int** y **char**.

- Resumen de reglas semánticas.
 - o Ningún identificador es declarado dos veces en el mismo ámbito
 - o Ningún identificador es utilizado antes de ser declarado.
 - o El programa contiene una definición de un método **main** sin parámetros, en donde se empezará la ejecución del programa.
 - o **num** en la declaración de un arreglo debe de ser mayor a 0.
 - o El número y tipos de argumentos en la llamada a un método deben de ser los mismos que los argumentos formales, es decir las firmas deben de ser idénticas.
 - o Si un método es utilizado en una expresión, este debe de devolver un resultado.
 - o La instrucción **return** no debe de tener ningún valor de retorno, si el método se declara del tipo **void**.
 - o El valor de retorno de un método debe de ser del mismo tipo con que fue declarado el método.
 - o Si se tiene la expresión `id[<expr>]`, `id` debe de ser un arreglo y el tipo de `<expr>` debe de ser **int**.
 - o El tipo de `<expr>` en la estructura **if y while**, debe de ser del tipo **boolean**.
 - o Los tipos de operandos para los operadores `<arith_op>` y `<rel_op>` deben de ser **int**.
 - o Los tipos de operandos para los operadores `<eq_ops>` deben de ser **int, char o boolean**, y además ambos operandos deben de ser del mismo tipo.
 - o Los tipos de operandos para los operadores `<cond_ops>` y el operador **!** deben de ser del tipo **boolean**
 - o El valor del lado derecho de una asignación, debe de ser del mismo tipo que la locación del lado izquierdo.